

Projeto 01 - Inteligência Computacional

Alisson da Silva Vieira

¹Universidade Tecnológica Federal do Parana (UTFPR)
Via Rosalina Maria Dos Santos, 1233 – 87.301-899 – Campo Mourão – PR – Brasil

alisson.v3@hotmail.com

1. Introdução

Neste projeto, foi disponibilizado pelo professor dois conjuntos de dados [Kaggle 2022, Diego Bertolini 2022]. Nosso objetivo com eles, é demonstrar o *Template Mathing*, uma técnica de processamento de imagens, que visa identificar partes de uma imagem que correspondam a uma outra de uma imagem de modelo. As técnicas de *Template Mathing* são flexíveis e relativamente simples de usar o que as torna um dos métodos mais populares de localização de objetos. Sua aplicabilidade é limitada principalmente pelo poder computacional disponível, pois a identificação de modelos grandes e complexos pode ser demorada [Adaptive Vision 2017]. Desta forma, devemos mostrar através dos conjuntos disponibilizados, que usando a própria imagem nas técnicas de *Template Mathing* pode ser eficaz em algumas tarefas, e ineficiente em outras.

2. Etapa A

Nesta etapa, foi utilizado o conjunto [Kaggle 2022], e desses, foi selecionado 10 imagens aleatórias para cada uma das classes: circle; square; star; triangle. Para cada uma das imagens da mesma classe, foi calculado o Pearson Correlation Coefficient [StatisticsHowTo 2022] e o Mean Squared Error [StatisticsHowTo 2022]. Depois desse experimento, para cada imagem de todas as classes, foi calculado novamente as duas métricas, porém, foi em relação as imagens de classes diferentes. Podemos ver os resultados na sessão 2.1.

2.1. Resultados

Segmentação	Técnica	Resultado	Desvio Padrão
Entre a mesma classe	<i>Pearson Correlation Coefficient</i>	0.7598	0.1520
	<i>Mean Squared Error</i>	4.2533e+03	2.1545e+03
Entre classes diferentes	<i>Pearson Correlation Coefficient</i>	0.6728	0.0911
	<i>Mean Squared Error</i>	7.0346e+03	2.1892e+03

Table 1. Etapa A: Comparação entre as métricas sob os dois tipos de segmentação.

Conseguimos ver na Tabela 1 que, o valor da métrica de Pearson Correlation Coefficient, o valor é ligeiramente maior para os elementos da mesma classe. Também conseguimos notar que o valor da métrica do Mean Squared Error é maior quando comparado os elementos de classes diferentes. Ou seja, ambos os casos evidenciam que se obtém melhores resultados quando a comparação é feita sob elementos da mesma classe.

3. Etapa B

Nesta etapa, foi utilizado o conjunto [Diego Bertolini 2022], e desses, foi selecionado 3 imagens aleatórias para cada uma das classes: opalus; mono; capillipes. De forma semelhante a Etapa A (Seção 2), para cada uma das imagens da mesma classe, foi calculado o Pearson Correlation Coefficient [StatisticsHowTo 2022] e o Mean Squared Error [StatisticsHowTo 2022]. E também, para cada imagem de todas as classes, foi calculado novamente as duas métricas, porém, foi em relação as imagens de classes diferentes. Podemos ver os resultados na sessão 3.1.

3.1. Resultados

Segmentação	Técnica	Resultado	Desvio Padrão
Entre a mesma classe	<i>Pearson Correlation Coefficient</i>	0.8457	0.0860
	<i>Mean Squared Error</i>	4.8427e+03	2.5338e+03
Entre classes diferentes	<i>Pearson Correlation Coefficient</i>	0.5610	0.0802
	<i>Mean Squared Error</i>	1.5103e+04	2.8200e+03

Table 2. Etapa B: Comparação entre as métricas sob os dois tipos de segmentação.

Conseguimos ver na Tabela 2 que, neste experimento, o valor da métrica de Pearson Correlation Coefficient é maior para os elementos da mesma classe, com um desvio padrão baixo. Também conseguimos notar que o valor da métrica do Mean Squared Error é muito maior quando comparado os elementos de classes diferentes. Conseguimos notar o mesmo padrão notado na Etapa A 2.1 com os dois casos evidenciando que quando a comparação é feita pelos elementos da mesma classe, se obtém melhores resultados.

4. Conclusão

Desta forma, através dessa atividade, conseguimos notar que as vantagens de se utilizar técnicas de *Template Matching* é que são técnicas relativamente simples, e que não da área de *Machine Learning*, e sim da área de processamento de imagens, dessa forma, seu custo depende apenas do processamento das imagens. Pelos resultados, notamos que essas técnicas possuem resultados muito satisfatórios quando usado para comparar instancias da mesma classe.

Podemos citar como desvantagem, o fato de que ao realizar a comparação entre instancias de classes diferentes, o resultado tende a ser menor. Também é válido ressaltar que quanto maior for o tamanho das instancias, maior será o custo de processamento.

References

- Adaptive Vision (2017). Template matching. https://docs.adaptive-vision.com/4.7/studio/machine_vision_guide/TemplateMatching.html. Accessed: 12 set. 2022.
- Diego Bertolini (2022). Folhas.zip. <https://www.dropbox.com/s/fmbq1bpay5joaax/Folhas.zip?dl=0>. Accessed: 12 set. 2022.
- Kaggle (2022). Four shapes. <https://www.kaggle.com/datasets/smeschke/four-shapes>. Accessed: 12 set. 2022.

StatisticsHowTo (2022). Mean squared error. <https://www.statisticshowto.com/probability-and-statistics/statistics-definitions/mean-squared-error/>. Accessed: 12 set. 2022.